




Рекомендательные системы

Николай Анохин




Информация о курсе

Николай Анохин

Академический опыт




Индустриальный опыт



Навыки




Олег Сапрыкин



Евгений Кувшинов

Маргарита Маркова

Сергей Малышев



Роман Логойда

Как задать вопрос

- Голосом
- В специально выделенное для этого время
- Перед тем как спросить будет хорошим тоном поставить несколько знаков вопроса

20:23 Саша: ????

20:23 Преподаватель: Ждём вопроса от Саши

20:24 Саша: Какая метрика хорошо работает в задаче рекомендаций?

Если что-то пошло не так

- Пропал голос
- Исчезло изображение
- Плохо слышно
- Любые проблемы другого характера

Сразу пишем в чат много минусов и не ждем других участников. Если вы увидели, что в чате кто-то написал много минусов, а у вас всё хорошо, то поставьте несколько плюсов:

20:24 Петя: - - - - -

20:25 Саша: ++++

20:25 Ольга: +++++++

Пройдя этот курс, вы...

- Разработаете свой рекомендательный сервис (почти) с нуля
- Сможете выбирать правильные инструменты под конкретную задачу
- Узнаете о проблемах, возникающих в боевых RS, и научитесь их решать
- Будете в курсе SOTA моделей и задач RS, над которыми работают ученые
- Подготовитесь к собеседованию по RS на junior позицию

ML Инженер




Репозиторий: <https://github.com/anokhin/recsys-course-spring-2026>

Чат курса: TODO

- Вопросы вне занятия можно задать в личке или в чате курса (лучше)
- Тегайте нас, чтобы мы не пропустили ваш комментарий в общем потоке сообщений
- Если ответа не последовало в течении 24 часов, то мы, вероятно, не увидели ваше сообщение. Не стесняйтесь его продублировать

Краткий обзор рекомендательных систем

Recommender Systems (RS) are software tools and techniques providing suggestions for **items** to be of use to a **user** [RRSK10].



THE TINDER SWINDLER



Play



More Info




16+

TV Shows



Trending Now



THE
TINDER
SWINDLER

1



Play



More Info



16+

TV Shows



4



2




Trending Now



4



3



RS в индустрии и науке

Компании

Amazon.com, YouTube, Netflix, Yahoo, Tripadvisor, Spotify, Booking.com

Конференции

RecSys, KDD, WSDM, SIGIR

Книги

Recommender Systems Handbook [RRSK10], Mining of Massive datasets [LRU14]

RS vs другие задачи ML [SBE⁺21]

- RS ориентированы на продакшен
- Наблюдаемые данные очень разреженные
- Отсутствующие данные – missing not-at-random
- Отсутствующие данные – либо ненаблюдаемые позитивные, либо негативные
- Рекомендательные сервисы живут в петле обратной связи

Зачем RS бизнесу

- Увеличить продажи
- Продвигать более разнообразные айтемы
- Улучшить пользовательский опыт
- Добиться большей лояльности
- Лучше понимать пользователей



Зачем RS пользователям

- Найти лучший товар
- Найти **все** подходящие товары
- Найти последовательность или набор товаров
- Залипнуть



КИНОПОИСК




Зачем RS инженерам




- Делать высоконагруженный отказоустойчивый сервис :D
- Анализировать большие данные
- Окунуться в волшебный мир матана машинного обучения
- Объективно измерять результат своей работы
- Узнать много нового о людях
- Все это за зарплату

Обзор типичных компонентов RS / Mendeley (2016) [JH16]



Машинное обучение – небольшая часть рекомендательного сервиса. Другие компоненты часто требуют не меньше усилий.


Рекомендации айтемов из больших каталогов / Youtube (2016) [CAS16]




Айтемов так много, что учесть **полный контекст** не может даже Google. Для быстрого отбора кандидатов применяются грубые фильтры.

Уровни вычислений и двухэтапный рекомендатель

[Yan21]



Как выбрать техническую метрику



фидбэк на рекоменда-
ции

- Явный/explicit
- Неявный/implicit
- Отложенный/delayed

Какие пользовательские данные использовать для метрики?


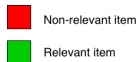
- События, интересные бизнесу: их мало и долго ждать
- Быстрые события: их много, но они хуже отражают задачу

Цель	rel	cov	div	ser	poll
Бизнесу					
Увеличить продажи	✓			✓	
Продвигать более разнообразные айтемы		✓	✓		
Улучшить пользовательский опыт	✓		✓	✓	✓
Добиться большей лояльности					✓
Лучше понимать пользователей					✓
Пользователям					
Найти лучший товар	✓			✓	✓
Найти все подходящие товары	✓	✓			✓
Найти последовательность или набор товаров	✓			✓	✓
Залипнуть	✓		✓	✓	✓

Precision@k, Recall@k

$$\text{Precision@k} = \frac{\text{no. relevant items}}{k}$$


$$\text{Recall@k} = \frac{\text{no. relevant items in } k}{\text{total no. relevant items}}$$



- Легко интерпретировать
- Легко реализовать


- Нечувствительны к порядку внутри k
- Не дают общей картины для любого k

Normalized Discounted Cumulative Gain



- Учитывает не только бинарный фидбэк
- Хорошо учитывает позицию


- Сложно интерпретировать



Content-based RS

Идея


Рекомендуем пользователю айтемы, похожие на те, что нравились ей раньше



Collaborative filtering²-based RS

Идея

Рекомендуем пользователю айтемы, которые понравились похожим на нее пользователям. Пользователи похожи, если они похоже оценивают одни и те же айтемы.



²Оскар за худшее название алгоритма

		Item			
		W	X	Y	Z
User	A		4.5	2.0	
	B	4.0		3.5	
	C		5.0		2.0
	D		3.5	4.0	1.0

Rating Matrix

=

User	A	1.2	0.8
	B	1.4	0.9
	C	1.5	1.0
	D	1.2	0.8

User
Matrix

X

		W	X	Y	Z
		1.5	1.2	1.0	0.8
		1.7	0.6	1.1	0.4

Item
Matrix




Figure 2. A simplified illustration of the latent factor approach, which characterizes both users and movies using two axes—male versus female and serious versus escapist.

Простые автоэнкодеры

SLIM [NK11] / EASE [Ste19]

$$\hat{A} = AW,$$

где

- A – матрица взаимодействий
- $\hat{A}$ – предсказанные взаимодействия
- $W_{:,j}$ – колонка весов агрегации для j айтема ($W_{ij} \geq 0$ (SLIM), $W_{jj} = 0$).

Implicit ALS (iALS) [RKZK22]

Давайте обучим модель на implicit feedback, но вместо семплирования implicit негативных примеров - используем вообще все негативные примеры.

$$\mathcal{L} = \sum_{(u,i) \in S} ((\mathbf{q}_i^T \mathbf{p}_u) - 1)^2 + \alpha \sum_{u \in U} \sum_{i \in I} (\mathbf{q}_i^T \mathbf{p}_u)^2 + \lambda R(\mathbf{P}, \mathbf{Q})$$

$$R(\mathbf{P}, \mathbf{Q}) = \sum_{u \in U} (U(u) + \alpha |U|) \|\mathbf{p}_u\|_F^2 + \sum_{i \in I} (I(i) + \alpha |I|) \|\mathbf{q}_i\|_F^2$$

При расчете аналитических решений для векторов $\mathbf{p}_u$, $\mathbf{q}_i$ - значительная часть вычислений является общей. Её нужно посчитать только один раз и дальше переиспользовать в рамках одного шага ALS.

Что дальше

Что нужно знать до начала модуля

Базовая математика

- Операции над векторами и матрицами.
- Дифференцирование и нахождение минимумов функций.
- Базовые алгоритмы и структуры данных.

Основы машинного обучения

- Постановка задачи ML, классические алгоритмы.
- Базовое представление о том как работают современные нейронные сети.
- Знакомство с рекомендательными системами.

Технические скиллы

- Знание языка python.
- Знакомство с Docker, умение запустить контейнер.
- Умение пользоваться git.
- Небольшой опыт PySpark.
- Знакомство с архитектурой высоконагруженных сервисов (БД + Big Data).

Программа курса

Неделя	Тема	Квиз	Семинар	Домашка
0	Основные подходы рекомендательных систем		✓	
1	Рекомендательные системы в production	✓	✓	
2	Нейронные сети для генерации кандидатов	✓	✓	
3	Нейронные сети для ранжирования	✓	✓	✓
4	Большие рекомендательные модели	✓	✓	
5	Графовые нейронные сети в рекомендациях	✓		
6	Разнообразие в рекомендациях	✓	✓	✓
7	Нерешённые проблемы рекомендательных систем	✓	✓	
8	Uplift моделирование	✓	✓	✓
9	Reinforcement learning для рекомендаций	✓	✓	

Оценка $\in [0, 100]$

- Идеальное выполнение домашек $25 + 35 = 60$
- Идеальное выполнение квизов и домашки = 100
- Дополнительные баллы можно получить на зачете

Литература I

-  Paul Covington, Jay Adams, and Emre Sargin, Deep neural networks for youtube recommendations, Proceedings of the 10th ACM Conference on Recommender Systems (New York, NY, USA), RecSys '16, Association for Computing Machinery, 2016, p. 191–198.
-  Kris Jack, Ed Ingold, and Maya Hristakeva, Mendeley suggest architecture, Oct 2016.
-  Jure Leskovec, Anand Rajaraman, and Jeffrey David Ullman, Mining of massive datasets, 2nd ed., Cambridge University Press, USA, 2014.
-  Xia Ning and George Karypis, Slim: Sparse linear methods for top-n recommender systems., ICDM (Diane J. Cook, Jian Pei, Wei Wang, Osmar R. Zaiane, and Xindong Wu, eds.), IEEE Computer Society, 2011, pp. 497–506.

Литература II

-  Steffen Rendle, Walid Krichene, Li Zhang, and Yehuda Koren, Revisiting the performance of ials on item recommendation benchmarks, Proceedings of the 16th ACM Conference on Recommender Systems, 2022, pp. 427–435.
-  Francesco Ricci, Lior Rokach, Bracha Shapira, and Paul B. Kantor, Recommender systems handbook, 1st ed., Springer-Verlag, Berlin, Heidelberg, 2010.
-  Harald Steck, Linas Baltrunas, Ehtsham Elahi, Dawen Liang, Yves Raimond, and Justin Basilico, Deep learning for recommender systems: A netflix case study, AI Magazine **42** (2021), no. 3, 7–18.
-  Harald Steck, Embarrassingly shallow autoencoders for sparse data, The World Wide Web Conference (New York, NY, USA), WWW '19, Association for Computing Machinery, 2019, p. 3251–3257.

Литература III



Ziyou Yan, System design for recommendations and search,
eugeneyan.com (2021).